

现代大模型综述：从 Transformer 到线性注意力

1. 引言

近年来，大语言模型（LLM）彻底改变了人工智能领域。从早期的 RNN 到如今的 Transformer，再到新兴的线性注意力架构，模型架构的演进始终围绕着两个核心矛盾：**训练效率（并行性）与推理效率（成本与长序列能力）**。本文将梳理这一演化历史，重点阐述 Transformer 为何成功，以及线性注意力（Linear Attention）如何通过三代演进，试图在保持 Transformer 性能的同时找回 RNN 的推理优势。

2. RNN：串行计算

在 Transformer 出现之前，RNN（循环神经网络）及其变体 LSTM/GRU 是处理序列数据的主流。然而，它们在处理大规模数据和长序列时遇到了难以克服的物理障碍。

2.1 无法并行训练 (Sequential Computation)

RNN 的核心公式定义了当前时刻的状态 h_t 严格依赖于上一时刻的状态 h_{t-1} ：

$$\text{## } h_t = \sigma(W_h h_{t-1} + W_x x_t + b) \text{ ##}$$

其中 σ 是非线性激活函数（如 tanh 或 ReLU）。

- **时间依赖链**：为了计算第 100 个时间步的 h_{100} ，必须先计算 h_1 ，而 h_1 又依赖 h_0 ……直到 h_{99} 。
- **GPU 利用率低**：现代 GPU 擅长进行大规模矩阵并行运算（如一次性计算所有 Token 的 $Q \cdot K^T$ ），但 RNN 这种“接力跑”式的计算模式迫使 GPU 必须等待上一步完成才能进行下一步。这导致在长序列训练时，GPU 大部分计算单元处于闲置状态，训练速度极慢。

2.2 梯度消失与爆炸 (Gradient Vanishing & Exploding)

RNN 难以捕捉长距离依赖（Long-term Dependencies）的根本原因在于反向传播算法（BPTT）。

假设我们要计算时刻 T 的损失 L_T 对时刻 0 的输入 x_0 的梯度，根据链式法则：

$$\text{## } \frac{\partial L_T}{\partial x_0} = \frac{\partial L_T}{\partial h_T} \cdot \frac{\partial h_T}{\partial h_{T-1}} \cdots \frac{\partial h_1}{\partial h_0} \cdot \frac{\partial h_0}{\partial x_0} \text{ ##}$$

其中关键项是连乘部分：

$$\text{## } \prod_{k=1}^T \frac{\partial h_k}{\partial h_{k-1}} = \prod_{k=1}^T W_h^T \cdot \text{diag}(\sigma'(z_k)) \text{ ##}$$

- **指数级衰减/增长**：如果权重矩阵 W_h 的特征值（Spectral Radius）小于 1，经过 T 次连乘后，梯度会趋近于 0（梯度消失）；如果大于 1，则会趋近于无穷大（梯度爆炸）。
- **例子**：考虑一个简单的句子：“Alice went to the kitchen ... [100 words] ... and she cooked dinner.”
 - 为了预测 “she”，模型需要利用 100 个词之前的 “Alice”的信息。
 - 在 RNN 中，“Alice”的信息需要经过 100 次矩阵乘法和非线性变换。如果每次变换保留 90% 的信息（0.9），那么 100 步后仅剩 $0.9^{100} \approx 0.000026$ 。

- 这意味着模型在更新参数时，几乎“感觉”不到 "Alice" 对 "she" 的影响，从而导致模型“遗忘”了主语。

虽然 LSTM 和 GRU 通过引入门控机制（Gating）缓解了这个问题，但并未从根本上解决串行计算的瓶颈。

3. Transformer：并行与注意力

2017 年，Google 提出的《Attention Is All You Need》改变了一切。它不仅是一个新架构，更是一种计算范式的转移。Transformer 的强大不仅仅在于并行训练，更在于其组件设计的精妙之处。

3.1 输入层：词向量空间 (Token Embeddings)

在进入复杂的注意力机制之前，我们首先要解决的问题是：**如何让计算机理解单词？**

- 离散符号到连续向量：**计算机无法直接处理 "Apple" 或 "Banana" 这样的字符串。我们需要建立一个查找表（Embedding Table），将每个词映射为一个固定长度的实数向量（例如 4096 维）。
- 语义空间：**这个向量空间具有良好的几何性质。语义相近的词，在空间中的距离更近。
 - 经典例子：** $\text{Vector}(\text{King}) - \text{Vector}(\text{Man}) + \text{Vector}(\text{Woman}) \approx \text{Vector}(\text{Queen})$ 。
 - 这意味着模型在输入层就已经具备了初步的推理能力。

3.2 训练范式：自回归生成 (Autoregression)

现代 LLM（如 GPT 系列）通常采用**自回归（Autoregressive）**的方式进行训练。

- 目标：**预测下一个 Token。即计算概率 $P(w_t | w_1, w_2, \dots, w_{t-1})$ 。
- 过程：**模型读入当前的上下文，预测下一个最可能出现的词。然后将这个词加入上下文，继续预测下个词。这就像人类写文章一样，一个字一个字地往后写。

3.3 Self-Attention：信息的“路由”与“聚合”

Transformer 的核心在于自注意力机制（Self-Attention）。对于初学者来说，直接看矩阵公式 $\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d}})V$ 可能比较抽象。让我们把它拆解开来，看看对于序列中的某一个词，到底发生了什么。

3.3.1 核心直觉：回顾历史 (Looking Back)

在自回归推理中，模型只能看到**当前和过去的信息**。想象模型正在生成句子：“**Alice likes ...**”。当前输入是 “likes”，模型需要预测下一个词（比如 “Bob”）。为了做出准确预测，模型必须回顾历史，搞清楚“谁”在喜欢。

Self-Attention 的本质就是：**用当前词（Query）去查询历史记忆中所有的词（Key），根据匹配程度（Attention Score）将它们的内容（Value）加权融合过来。**

Q 与 K 的相似度理论：为什么我们要计算 $Q \cdot K^T$ ？在几何上，两个向量的点积（Dot Product）衡量了它们的**相似度或对齐程度**。

- 如果 Q 和 K 指向相同的方向，点积最大（关注度最高）。
- 如果 Q 和 K 垂直（无关），点积为 0（不关注）。
- 这就像数据库查询： Q 是你的搜索关键词， K 是数据库中每条记录的索引标签。点积越高，说明这条记录越符合你的搜索意图。

3.3.2 序列形式公式 (The Sequence Form)

对于序列中的第 t 个 Token，其输出向量 y_t 的计算公式如下（注意求和上限是 t ，不能看未来）：

$$\text{y}_t = \sum_{i=1}^t \underbrace{\left(\text{softmax} \left(\frac{\mathbf{q}_t \cdot \mathbf{k}_i}{\sqrt{d}} \right) \alpha_{t,i} \right)}_{\text{(注意力权重)}} \mathbf{v}_i$$

- \mathbf{q}_t : 当前词 t 的查询向量 (Query)。
- \mathbf{k}_i : 历史中第 i 个词的键向量 (Key)， $i \leq t$ 。
- \mathbf{v}_i : 历史中第 i 个词的值向量 (Value)。
- $\alpha_{t,i}$: 第 t 个词对第 i 个词的关注度。

3.3.3 图解与例子：一次真实的推理步骤

假设模型已经处理了 "Alice"，现在轮到 "likes"。当前时刻： $t=2$ 输入： likes 历史上下文： [Alice, likes] (注意：Bob 还没出现，是我们要预测的目标)

我们来看看如何计算 "likes" 的输出向量，以便预测下一个词。

第一步：打分 (Matching) "likes" 发出查询 $\mathbf{q}_{\text{likes}}$ ，回顾历史（包括自己）：

$$\begin{aligned} \mathbf{q}_{\text{likes}} \cdot \mathbf{k}_{\text{Alice}} &= 0.9 \quad (\text{很高，因为需要找到主语是谁}) \\ \mathbf{q}_{\text{likes}} \cdot \mathbf{k}_{\text{likes}} &= 0.5 \quad (\text{关注自己，提取动词本身的意义}) \end{aligned}$$

(注：此时模型完全不知道 Bob 的存在)

第二步：归一化 (Softmax) 将分数转化为概率：

$$\text{Softmax}([0.9, 0.5]) \approx [0.6, 0.4]$$

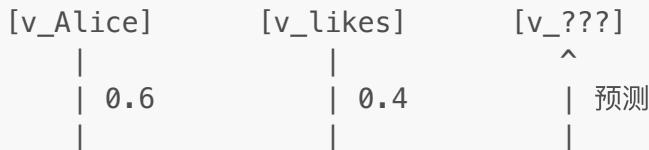
↑ ↑
Alice likes

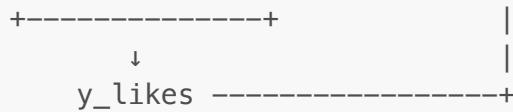
第三步：聚合 (Aggregation) 根据权重，融合历史信息：

$$y_{\text{likes}} = 0.6 * v_{\text{Alice}} + 0.4 * v_{\text{likes}}$$

结果： 得到的 y_{likes} 向量融合了 "Alice" (主语) 和 "likes" (谓语) 的信息。这个向量经过后续层处理，最终会预测出高概率的词："Bob" 或 "Apples"。

可视化流程：





3.3.4 多头注意力 (Multi-Head Attention)

- 如果只有一个头， "likes" 可能只能关注到语法成分。但它还需要关注情感色彩等。
- 多头机制允许模型在不同的子空间里并行关注不同的特征。Head 1 关注指代，Head 2 关注句法依存，Head 3 关注上下文情感。

3.4 MLP (Feed-Forward Networks): 知识的“存储”与“加工”

在 Attention 层之后，总是紧跟着一个 MLP（多层感知机）层。为什么？

- 结构：**通常是 Linear → Activation (GeLU/SwiGLU) → Linear。它独立地作用于每个 Token，不涉及 Token 间的交互。
- 分工：**
 - Attention** 负责 **Token 之间** 的信息流动 (Mixing information between tokens)。它把上下文信息搬运到当前 Token。
 - MLP** 负责 **Token 内部** 的信息加工 (Mixing information within a token)。
- 深度理解：键值记忆网络 (Key-Value Memories)：**
 - 有研究 (Geva et al.) 认为，MLP 层充当了模型的知识库。
 - 第一层 Linear 类似于检测某种模式 (Key)，激活函数筛选模式，第二层 Linear 输出该模式对应的属性或结果 (Value)。
 - 例如，Attention 把 "法国" 和 "首都" 搬运到了一起，MLP 层检测到这个组合，然后输出 "巴黎"。

3.5 位置编码：赋予序列秩序

Self-Attention 本质上是集合运算（置换不变性），无法区分 "A hit B" 和 "B hit A"。必须显式注入位置信息。

- 绝对位置编码 (Sinusoidal / Learnable)：**
 - 直接将位置向量 P_i 加到输入 X_i 上。
 - 缺点：**外推性差。训练时只见过长度 1024，推理时遇到 2048 就不知道 P_{2048} 是什么，或者正弦波从未见过的相位会导致混乱。
- 相对位置编码 (ALiBi)：**
 - 不加在输入上，而是直接加在 Attention Score 上。距离越远，扣分越多 ($QK^T - m \cdot \log |i-j|$)。
 - 优点：**外推性极强，训练短序列，推理长序列效果好。
- 旋转位置编码 (RoPE - Rotary Positional Embedding)：**
 - 当前主流 (LLaMA, Qwen 等使用)。
 - 通过旋转向量的角度来编码相对位置。 q_i 旋转 θ_i , k_j 旋转 θ_j ，它们的点积只与相对距离 $(i-j)\theta$ 有关。
 - 优点：**完美结合了绝对位置的实现便利性和相对位置的数学性质，外推性较好。

3.6 残差连接与层归一化：深度的基石 (Residuals & LayerNorm)

为什么 Transformer 可以堆叠到上百层而不会梯度消失？这归功于 **残差连接 (Residual Connection)**。

3.6.1 残差连接：缓解梯度消失

在深层网络中，如果每一层都是 $x_{l+1} = F(x_l)$ ，那么反向传播时的梯度是连乘的： $\frac{\partial L}{\partial x_0} = \frac{\partial L}{\partial x_L} \cdot \prod \frac{\partial F}{\partial x}$ 。一旦某层的导数小于 1，连乘几十次后梯度就会趋近于 0，导致梯度消失。

Transformer 采用了残差结构： $x_{l+1} = x_l + F(x_l)$ 其中 $F(x_l)$ 是 Attention 或 MLP 层的计算结果。

数学原理：根据链式法则，反向传播时的梯度计算如下：

$$\frac{\partial x_{l+1}}{\partial x_l} = 1 + \frac{\partial F(x_l)}{\partial x_l}$$

最终的梯度流向是： $\frac{\partial L}{\partial x_l} = \frac{\partial L}{\partial x_{l+1}} \cdot \left(1 + \frac{\partial F(x_l)}{\partial x_l} \right)$

- **恒等映射 (Identity Mapping)：**公式中的常数项 1 保证了梯度可以直接传回前一层。
- **梯度保持：**即使某层的非线性变换部分 $\frac{\partial F}{\partial x_l}$ 梯度很小，梯度信号依然可以通过 1 这一项继续向前传播。这有效缓解了梯度消失问题，使得训练深层网络成为可能。

3.6.2 层归一化 (LayerNorm / RMSNorm)

$$x_{l+1} = \text{LayerNorm}(x_l + F(x_l))$$

- **作用：**将每一层的输出归一化到均值为 0，方差为 1。
- **意义：**这防止了数值在深层网络中剧烈波动（梯度爆炸），进一步稳定了训练过程。

3.7 表达能力与深度：电路的升级

为什么 Transformer 需要堆叠几十层？

- **残差流 (Residual Stream)：**
 - Transformer 的主干是一个贯穿始终的向量流 $x + \text{Sublayer}(x)$ 。
 - 每一层 (Attention 或 MLP) 都是从这个流中“读”出信息，处理后，再“写”回一个增量 (Residual Update)。
- **归纳头 (Induction Heads) 与多步推理：**
 - 第 1 层：可能只是简单的词法关注。
 - 第 2 层：可以利用第 1 层搬运来的信息。
 - **Induction Head** 是 In-context Learning 的核心电路。它由两层 Attention 组成：
 - Layer 1 关注当前 Token 的上一个 Token (复制历史)。
 - Layer 2 搜索历史中出现过类似“上一个 Token”的地方，并把那之后的 Token 搬运过来。
 - **功能：**实现了“如果 A 后面通常跟 B，那么这次看到 A，我也预测 B”的模式复制能力。
 - 随着层数加深，模型能组合出极其复杂的逻辑电路，实现推理能力。

3.8 自回归推理：从向量回归文本

当模型经过几十层的计算，输出了最后一个 Token 的向量 h_{last} 后，我们如何得到文本？

1. Unembedding (反嵌入)：

- 将 h_{last} 乘以 Embedding 矩阵的转置 (或单独的输出头)，得到一个长度为词表大小 (如 50,000) 的向量 **Logits**。

- Logits 中的每个数值代表对应词的“得分”。

2. Softmax:

- 将 Logits 转化为概率分布 \$P\$。
- $P(\text{text}{"apple"}) = 0.1, P(\text{text}{"banana"}) = 0.05, \dots$

3. 采样 (Sampling):

- **Greedy**: 直接选概率最大的词。
- **Top-K / Top-P (Nucleus)**: 从概率最高的 K 个词或累积概率为 P 的集合中随机抽取。这增加了生成的多样性。

4. 循环 (Loop):

- 选出的词被追加到输入序列末尾，再次输入模型，预测下一个词。这就是自回归过程。

3.8 计算复杂度瓶颈

尽管 Transformer 极其强大，但它付出了昂贵的代价：二次方复杂度。

- **计算量与显存**: 计算 Attention 分数矩阵 $A = QK^T$ 需要生成一个 $N \times N$ 的矩阵。
- **直观感受**:
 - 序列长度 $N=1,000$ 时， $N^2 = 1,000,000$ 。
 - 序列长度 $N=100,000$ 时， $N^2 = 10,000,000,000$ 。
- 这导致标准 Transformer 难以处理长文档、长对话或基因序列等超长上下文任务。显存占用随长度爆炸式增长，推理时的 KV Cache 也消耗巨大。

4. 线性注意力的演进：回归 $O(N)$ 的尝试

为了解决 $O(N^2)$ 问题，研究者试图将 Attention 线性化，使其推理复杂度降回 $O(N)$ （类似 RNN），同时保留并行训练能力。这一过程经历了三代演进。

4.1 第一代：核方法 (Kernel-based) 与“词袋”困境

为了突破计算瓶颈，研究者们回顾了矩阵乘法的结合律。

4.1.1 线性化原理：结合律的应用

标准 Attention 的计算顺序是先算 QK^T （得到 $N \times N$ 矩阵），再乘 V : $QK^T \times V$

如果我们能去掉 Softmax，或者用某种核函数 $\phi(\cdot)$ 近似 Softmax，使得 $\text{Sim}(Q, K) = \phi(Q)\phi(K)^T$ ，那么公式就可以重写为： $Q\phi(K)^T V$

• 计算优势：

- 先计算 $\phi(K)^T V$ ，得到一个 $D \times D$ 的矩阵（ D 是特征维度，通常很小，如 64 或 128）。这一步复杂度是 $O(N \times D^2)$ 。
- 再用 $\phi(Q)$ 去乘这个 $D \times D$ 矩阵。
- 总复杂度从 $O(N^2)$ 降到了 $O(N)$ 。这意味着推理速度和显存占用不再随序列长度爆炸。

4.1.2 递归形式 (Recurrent View)

这种线性 Attention 可以被写成类似 RNN 的递归形式。定义记忆状态 $S_t = \sum_{i=1}^t \phi(k_i) v_i^T$:
 $S_t = S_{t-1} + \phi(k_t) v_t^T$ $y_t = \phi(q_t) S_t$

键值记忆：我们可以将矩阵 S_t 理解为一个联想记忆库。

- **写入 (Write):** $S_t = S_{t-1} + k_t v_t^T$ 。这本质上是 Hebbian Learning (赫布学习规则) 的一种形式。我们将键值对 (k_t, v_t) 存储到矩阵中。
- **读取 (Read):** $y_t = S_t q_t$ 。当我们用查询向量 q_t 去乘矩阵时，实际上是在进行检索：
 $y_t = (\sum k_i v_i^T) q_t = \sum v_i (k_i^T q_t)$ 结果是所有存储的 v_i 的加权和，权重正是查询 q_t 与键 k_i 的相似度。

4.1.3 致命缺陷：“词袋”效应 (Bag of Words)

虽然解决了速度问题，但第一代线性 Attention (如 Linear Transformer, Performer) 效果通常不如标准 Transformer。

- **记忆是简单的累加：**观察公式 $S_t = \sum \phi(k_i) v_i^T$ ，这本质上是一个求和操作。
- **缺乏遗忘机制：**模型被迫“记住”所有历史信息，无法根据当前上下文丢弃无关信息。随着序列变长， S_t 中积累的噪声越来越多，有效信号被淹没。
- **位置信息模糊：**虽然可以加位置编码，但由于记忆是加性的，模型很难区分“Alice hit Bob”和“Bob hit Alice”在深层语义上的区别（如果位置编码被淹没）。这被称为**词袋问题**——模型知道出现了哪些词，但搞不清它们的精确顺序和结构。

4.2 第二代：门控与选择机制 (Gated Decay / Selection)

为了解决“词袋”问题，研究者们意识到：记忆不能只是简单的累加，必须有选择地遗忘。

4.2.1 核心创新：数据依赖的衰减 (Data-Dependent Decay)

在第一代模型中，如果引入衰减，通常是固定的（如 $S_t = \lambda S_{t-1} + \dots$ ）。而在第二代模型 (Mamba, RWKV v5/v6, GLA) 中，衰减率 α_t 是由当前输入 x_t 动态计算的。

$$S_t = \alpha_t \odot S_{t-1} + \phi(k_t) v_t^T$$

其中 $\alpha_t \in [0, 1]$ 是一个门控向量。

4.2.2 选择机制 (Selection Mechanism)

Gu & Dao 在 Mamba 论文中将这种机制称为**选择机制**。它赋予了模型以下能力：

1. **过滤噪声：**遇到无意义的词（如停用词、无关插曲）时，将 α_t 设为接近 1（保持记忆），同时抑制新信息的写入。
2. **重置上下文：**当文章从“体育新闻”转折到“财经报道”时，模型可以将 α_t 设为接近 0，快速遗忘旧的体育上下文，为新信息腾出空间。

4.2.3 例子：抗噪任务

考虑任务：[关键信息 A] ... [大量噪声文本] ... [提问 A?]

- **第一代模型**: 在处理噪声时, 噪声不断累加到 S_t 中, 最终掩盖了 **关键信息 A**。
- **第二代模型**: 模型学会了在处理噪声时让“写入门”关闭, 或者让“遗忘门”保持开启, 从而让 S_t 几乎不受噪声干扰, 成功将 **关键信息 A** 传递到最后。

这一改进使得线性 Attention 模型首次在困惑度 (Perplexity) 和下游任务上匹敌甚至超越了同等规模的 Transformer。

4.3 第三代: Delta 规则与精确状态追踪 (Delta Rule / State Tracking)

尽管第二代模型表现优异, 但它们在处理**联想回忆 (Associative Recall)** 和 **精确状态更新** 任务时仍有短板。这催生了以 DeltaNet 和 RWKV v7 为代表的第三代线性注意力。

4.3.1 最后的短板: 变量赋值问题

想象一个代码执行任务:

1. `x = 5`
2. `...` (执行其他操作)
3. `x = 10`
4. `print(x)`

- **第二代模型**: 当看到 `x = 10` 时, 它会试图记住 `x: 10`。但由于它只能“衰减”旧信息, `x: 5` 的残余可能仍然存在。最终记忆可能是 `x: 7.5` (混合态)。
- **理想行为**: 在写入 `x = 10` 之前, 应该先**精确擦除掉** `x` 之前的值, 然后再写入新值。

4.3.2 Delta Rule: 从优化视角看推导

第三代模型引入了**减性更新 (Subtractive Update)**, 其数学本质是**在线梯度下降 (Online Gradient Descent)**。

推导来源: 我们可以把记忆矩阵 S 看作是一个试图拟合数据的线性模型。在时刻 t , 我们的目标是让记忆 S 能够根据键 K_t 正确检索到值 V_t (即让 S 记住这一对 KV 映射)。即希望: $S \cdot K_t \approx V_t$ (注: 这是写入/优化目标, 而模型实际输出时的读取操作依然是 $O_t = S \cdot Q_t$)

为了达到这个目标, 我们观察上一时刻的记忆 S_{t-1} 在当前数据上的表现, 并计算其误差 (Loss): $\mathcal{L} = \frac{1}{2} |S_{t-1} K_t - V_t|^2$

然后, 我们根据这个误差对 S_{t-1} 进行修正 (梯度下降): $\nabla_S \mathcal{L} = (S_{t-1} K_t - V_t) K_t$ (其中 $\nabla_S \mathcal{L}$ 代表梯度, 即“误差 \mathcal{L} 对记忆矩阵 S 的导数”, 它指明了 S 应该如何变化才能最快地增大误差。为了减小误差, 我们要反其道而行之, 减去梯度。)

$$S_t = S_{t-1} - \eta \nabla_S \mathcal{L}$$

代入梯度公式, 并设学习率为 β_t , 我们得到 Delta Rule 的核心公式: $S_t = S_{t-1} + \beta_t (V_t - S_{t-1} K_t)$

物理意义: 从“叠加”到“重写”

我们可以用**黑板写字**来类比这三代演进:

1. **第一代 (叠加)**: 你在黑板上写字, 写满了也不擦, 直接在旧字上面叠着写新字。最后黑板上一团漆黑, 什么也认不出来 (词袋效应)。

2. 第二代（衰减）：黑板上的字会随时间自动变淡。你在写新字之前，旧字已经淡了一些。但这只是被动的遗忘，你无法主动擦除某个特定的错误。
3. 第三代（Delta / 重写）：你手里拿了一个黑板擦。
 - **Predict**: 你先看一眼黑板上 K_t 这个位置现在写着什么 ($S_{t-1}K_t$)。
 - **Error**: 你对比一下你想写的内容 V_t 和黑板上现有的内容。
 - **Correct**: 你算出差值，精准地擦掉旧的痕迹，然后填上新内容。
 - 这实现了真正的**变量重写**（Variable Overwriting），就像在编程语言中执行 $x = 10$ 一样，旧的 $x=5$ 被彻底清除了。

这与卡尔曼滤波（Kalman Filter）中的“预测-校正”步骤有着异曲同工之妙。

如果展开公式，我们会发现它包含了一个显式的减法项： $S_t = S_{t-1} \underbrace{- \beta_t (S_{t-1} K_t)}_{\text{删除旧信息}} + \beta_t V_t K_t$

这意味着模型学会了在写入新信息之前，先将记忆矩阵在 K_t 方向上的投影减去。这实现了正交化，保证了新旧信息不会混淆。

4.3.3 RWKV v7 的实现

在 RWKV v7 的架构中，这一思想得到了工程化的落地。在 `src/model/rwkv_v7.rs` 或 `time_mix.rs` 中，我们可以观察到状态更新的核心逻辑包含类似以下的结构：

```
// 伪代码示意
let recall = state * k;          // 回忆旧值
let error = v - recall;          // 计算差异
state = state + error * k;       // 更新状态
```

（注：实际实现中包含复杂的 Head 维度处理和 LoRA 门控，但核心数学原理一致）。

这种机制使得 RWKV v7 不仅拥有 RNN 的推理速度，还具备了类似 Transformer 的精确“In-context Learning”能力，能够处理复杂的逻辑推理和状态追踪任务。

4.4 线性与非线性的辩证：为什么现代 RNN 是“线性”的？

在结束这一章之前，我们需要澄清一个常见的误区。当我们说 RWKV 或 Mamba 是“线性注意力”或“线性 RNN”时，指的是状态更新方程关于状态 S 是线性的。

4.4.1 为什么要线性递归？(Why Linear Recurrence?)

传统 RNN（如 LSTM）的状态更新包含非线性激活函数： $h_t = \tanh(W h_{t-1} + \dots)$ 这种非线性使得 h_t 无法直接展开为 h_0 的闭式解，必须一步步串行计算。

而现代线性 Attention 的更新方程（如 RWKV）： $S_t = A_t S_{t-1} + V_t K_t^T$ 这里没有 \tanh 或 sigmoid 包裹 S_{t-1} 。正是这种**线性递推关系**，使得我们可以利用**结合律**进行并行训练（Parallel Scan / Chunkwise Computation）。 $S_2 = A_2 (A_1 S_0 + V_1 K_1^T) + V_2 K_2^T$ 我们可以先算出所有 A 的累乘，再并行计算结果。

4.4.2 为什么不需要非线性递归？(Why is Linear Sufficient?)

既然去掉了递归中的非线性，模型会不会变“傻”？毕竟深度学习的核心就是非线性变换。

答案是：不会，因为我们有层数（Depth）。

- 分工明确：
 - **时间轴 (Time Mixing)**：线性递归负责在时间维度上搬运信息。它像一条传送带，高效地把过去的记忆 S_{t-1} 传给现在。
 - **特征轴 (Channel Mixing)**：每个 Block 中的 **MLP 层**（以及 Attention 中的 Output Projection）包含大量的非线性激活函数（GeLU, Swish）。
- 堆叠效应：
 - 虽然单层的递归是线性的，但当我们把“线性递归”和“非线性 MLP”交替堆叠几十层后，整个模型对输入的变换就是高度非线性的。
 - 这就像 Transformer：Self-Attention 内部也是线性的（加权求和），非线性主要来自 MLP 和多层堆叠。

结论：现代 RNN 放弃了“时间步上的非线性”以换取并行训练能力，并通过“深度的非线性”来保证模型的表达能力。这是一个极其划算的交易。

5. 总结

从 RNN 到 Transformer，我们获得了并行性；从 Transformer 到现代线性注意力（RWKV v7, Mamba），我们在保持并行性的同时，找回了 $O(1)$ 的推理效率，并正在通过 Delta Rule 攻克线性模型最后的短板——精确状态追踪。

6. 待办事项 (TODO)

- **并行训练与矩阵形式**：解释 Transformer 如何在训练阶段利用矩阵运算一次性处理整个序列（Teacher Forcing）。
- **因果掩码 (Causal Mask)**：详细解释如何在并行训练中防止模型“偷看”未来。